

# Estatística - Listas de Exercícios

Jorge Augusto Salgado Salhani

Novembro, 2022

## 1 Lista 5 - Estimação Pontual e Intervalo de Confiança

1. Seja  $X$  uma variável aleatória com distribuição uniforme  $Unif(0, a)$ . Note que  $E[X] = a/2$ , mas  $a$  é, em princípio, desconhecido. É planejado o seguinte experimento: são extraídas duas instâncias  $X_1$  e  $X_2$  de  $X$ , independentes. Qual a probabilidade de  $a > X_1 + X_2$ ?

Dado  $X_1 < a$ , para satisfazer a desigualdade,  $X_2$  é restrito a  $X_2 < a - X_1$ . Sendo  $f = Unif(0, a)$ , temos que

$$P(a > X_1 + X_2) = P(X_1 < a)P(X_2 < a - X_1) = \int_0^a f dx_1 \int_0^{a-X_1} f dx_2$$

Como  $f = 1/a$  para  $0 \leq x \leq a$  (para sua integral ser 1 em todo o espaço e ser definida como distribuição de probabilidade), temos que

$$\begin{aligned} P(a > X_1 + X_2) &= (1/a)^2 \int_0^a dx_1 \int_0^{a-X_1} dx_2 = (1/a)^2 \int_0^a (a - X_1) dx_1 \\ &= (1/a)^2 [(a)^2 - (1/2)(a)^2] = 1/2 \end{aligned}$$

Logo  $P(a < X_1 + X_2) = 1/2$ .

2. Seja  $X$  uma variável aleatória com distribuição de Bernoulli, com probabilidade  $p$  de tomar o valor 1 e  $1 - p$  de tomar o valor 0. Note que  $E[X] = p$ , mas  $p$  é desconhecido, em princípio. São extraídas  $n$  instâncias  $X_1, X_2, \dots, X_n$ , independentes. Sendo  $\bar{X} = \sum_k X_k/n$ , qual a probabilidade de  $\bar{X} \leq 0.9p$ ?

Sendo os eventos variáveis de Bernoulli com valor 0 e 1, a distribuição de  $X_1 + X_2 + \dots + X_n = \sum_k X_k$  segue distribuição binomial. Assim, sendo  $\bar{X} = \sum_k X_k/n$ , temos que  $n\bar{X} \sim Binom(n, np)$ . Logo

$$P(\bar{X} \leq 0.9p) = P(n\bar{X} \leq np0.9) = \sum_{i=0}^{\lfloor np0.9 \rfloor} \binom{n}{i} p^i (1-p)^{n-i}$$

3. Seja  $X$  uma variável aleatória com distribuição normal  $N(a, 1)$ . Note que  $E[X] = a$ , mas  $a$  é desconhecido, em princípio. São extraídas duas observações  $X_1, X_2$  de  $X$ , independentes. Qual a probabilidade de  $a < \min(X_1, X_2)$ ?

Como a função  $\min(X_1, X_2)$  não cria vínculo entre as variáveis, basta que  $X_1 < a$  e  $X_2 < a$ . Assim

$$P(a < \min(X_1, X_2)) = P(a < X_1)P(a < X_2).$$

Como  $N(a, 1)$  é simétrico em relação a  $a$ , então  $P(a < X_1) = 1/2 = P(a < X_2)$ . Logo  $P(a < \min(X_1, X_2)) = 1/4$ .

3. Seja  $X$  uma variável aleatória com distribuição normal  $N(\mu, 1)$ , cuja média  $\mu$  é desconhecida. Será extraída uma amostra de 4 elementos e com elas serão calculadas  $A = [\sum_i^4 X_i/4] - 1$  e  $B = [\sum_i^4 X_i/4] + 1$ .

A e B são variáveis aleatórias? A e B têm distribuição normal? Qual a média e desvio padrão de A e B? A e B são independentes?

Como A e B são definidas por variáveis aleatórias, A e B são também aleatórias.

Sabendo que se

$$X \sim N(\mu, \sigma^2) \implies Y = X + c \sim N(\mu + c, \sigma^2)$$

ou seja, soma de valores a uma variável aleatória de distribuição normal mantém a distribuição normal, mas com média deslocada, podemos usar esse fato para afirmar que A e B possuem também distribuição normal.

Além disso, sabendo que

$$X \sim N(\mu, \sigma^2) \implies Y = \sum_i^n X_i \sim N(n\mu, n\sigma^2) \quad (1)$$

Como  $\sum_i^4 X_i = 4(A + 1)$  e  $\sum_i^4 X_i = 4(B - 1)$ , então  $4(A + 1) \sim N(4\mu, 4\sigma^2)$  e  $4(B - 1) \sim N(4\mu, 4\sigma^2)$ .

Sabendo agora que

$$X \sim N(\mu, \sigma^2) \implies Y = cX \sim N(c\mu, c^2\sigma^2)$$

então, se  $Z_A = 4(A + 1)$ ,  $A = (1/4)Z_A - 1$  e portanto  $A \sim N(\mu - 1, (1/4)\sigma^2)$ . Análogo, temos se  $Z_B = 4(B - 1)$ ,  $B = (1/4)Z_B + 1$  e portanto  $B \sim N(\mu + 1, (1/4)\sigma^2)$ .

Por fim, como  $B = A + 2$ , A e B têm vínculo, e portanto, não são independentes.

5. Sejam A e B variáveis aleatórias do exercício anterior. Qual a probabilidade de  $\mu \notin [A, B]$ ?

Como  $B > A$ , pois  $B = A + 2$  então segue que

$$P(\mu \notin [A, B]) = 1 - P(A \leq \mu \leq B)$$

Como vale que

$$X \sim N(\mu, \sigma^2) \implies Y = (X - \mu)/\sigma \sim N(0, 1)$$

Então se  $A \sim N(\mu - 1, 1/4)$ , sendo  $\mu_A = \mu - 1$  e  $\sigma_A^2 = 1/4$ , então temos que  $Y_A = [A - (\mu - 1)]/(1/2)$  é tal que  $Y_A \sim N(0, 1)$ . Em termos de  $\mu$ , podemos escrever a relação  $-Y_A/2 + A + 1 = \mu$ .

Logo, rearranjando a desigualdade para  $\mu \notin [A, B]$ , temos que

$$\begin{aligned} P(\mu \notin [A, B]) &= 1 - P(A \leq \mu \leq A + 2) \\ &= 1 - P(A \leq A + 1 - Y_A/2 \leq A + 2) \\ &= 1 - P(-1 \leq -Y_A/2 \leq 1) = 1 - P(2 \geq Y_A \geq -2) \end{aligned}$$

Com  $Y_A \sim N(0, 1)$ , por fim

$$P(\mu \notin [A, B]) = 1 - \int_{-2}^2 N(0, 1) dx$$

6. Será extraída uma amostra de  $n$  elementos independentes  $X_1, X_2, \dots, X_n$  da variável  $X \sim N(1, \sigma^2)$ , da qual a variância  $\sigma^2$  é desconhecida. A parti dessa amostra será computada a estatística (o estimador)

$$Y^2 = \frac{1}{n-1} \sum_i (X_i - 1)^2$$

Qual a probabilidade de  $Y^2/2 \leq \sigma^2 \leq 2Y^2$ ?

Responder para  $n$  pequeno com distribuição  $\chi^2$  e para  $n$  grande, usando a aproximação do teorema central do limite. Comparar com  $n = 20$ .

Sabemos que

$$X \sim N(0, 1) \implies Q = \sum_i^k X_i^2 \sim \chi^2(k)$$

dessa forma, podemos tomar  $Z_i = (X_i - 1)/\sigma$  de modo que  $X_i \sim N(1, \sigma^2)$ , então  $Z_i \sim N(0, 1)$ . Logo, também podemos reescrever que  $(X_i - 1) = Z_i \sigma$ .

Assim, a estatística desejada pode ser reescrita como  $Y^2(n-1) = \sum_i (X_i - 1)^2 = \sum_i (Z_i \sigma)^2 = \sigma^2 \sum_i Z_i^2$ , fazendo com que  $Y^2(n-1)/\sigma^2 = Q \sim \chi^2$ . Ou também, em termos de  $\sigma^2$ , temos  $\sigma^2 = Y^2(n-1)/Q$ .

Para o intervalo desejado, temos que

$$\begin{aligned} P(Y^2/2 \leq \sigma^2 \leq 2Y^2) &= P(Y^2/2 \leq Y^2(n-1)/Q \leq 2Y^2) \\ &= P(1/[2(n-1)] \leq 1/Q \leq 2/(n-1)) \\ &= P(2(n-1) \geq Q \geq (n-1)/2) \end{aligned}$$

Logo

$$P(Y^2/2 \leq \sigma^2 \leq 2Y^2) = \int_{(n-1)/2}^{2(n-1)} \chi^2 dx$$

Caso  $n$  grande, é válida a aproximação de  $\chi^2$  para uma distribuição  $N(\mu, \sigma^2)$  tais que  $\mu = n$  e  $\sigma^2 = 2n$ . Assim

$$P(Y^2/2 \leq \sigma^2 \leq 2Y^2) = \int_{(n-1)/2}^{2(n-1)} N(n, 2n) dx$$

7. Será extraída uma amostra de  $n$  elementos independentes,  $X_1, X_2, \dots, X_n$  da variável  $X \sim N(\mu, \sigma^2)$ , da qual os parâmetros  $\theta = (\mu, \sigma^2)$  são desconhecidos. São computadas as estatísticas  $\bar{X}$  e  $S^2$

$$\bar{X} = \frac{1}{n} \sum_i X_i \quad S^2 = \frac{1}{n-1} \sum_i (X_i - \bar{X})^2$$

Qual a probabilidade de  $\bar{X} - S/10 \leq \mu \leq \bar{X} + S/10$ ?

Responder para  $n$  pequeno usando a distribuição  $t$  de Student e para  $n$  grande usando aproximação pela distribuição normal.

Sabendo que, se  $\bar{X}$ ,  $S^2$  definidos acima,

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

com  $t_{n-1}$  distribuição  $t$  de Student com  $n$  graus de liberdade, dessa forma, temos que

$$-TS/\sqrt{n} + \bar{X} = \mu$$

E o intervalo desejado pode ser reescrito na forma

$$\begin{aligned} P(\bar{X} - S/10 \leq \mu \leq \bar{X} + S/10) &= P(\bar{X} - S/10 \leq -TS/\sqrt{n} + \bar{X} \leq \bar{X} + S/10) \\ &= P(-S/10 \leq -TS/\sqrt{n} \leq +S/10) \\ &= P(-\sqrt{n}/10 \leq -T \leq \sqrt{n}/10) \\ &= P(\sqrt{n}/10 \geq T \geq -\sqrt{n}/10) \end{aligned}$$

Logo

$$P(\bar{X} - S/10 \leq \mu \leq \bar{X} + S/10) = \int_{-\sqrt{n}/10}^{\sqrt{n}/10} t_{n-1} dx$$

Para  $n$  grande e aproximação da distribuição  $t$  para uma normal, temos válido que

$$E[t_k] = 0 \quad Var[t_k] = \frac{k}{k-2}$$

Logo, para  $n$  grande a distribuição tende a  $N(0, k/k-2)$ , com  $k = n-1$ . Assim

$$P(\bar{X} - S/10 \leq \mu \leq \bar{X} + S/10) = \int_{-\sqrt{n}/10}^{\sqrt{n}/10} N(0, n/(n-3)) dx$$

8. Seja  $X$  uma variável aleatória com distribuição de Bernoulli, com probabilidade  $p$  de tomar valor 1 e  $1-p$  de tomar valor 0. Note que  $E[X] = p$ , mas  $p$  é desconhecido, em princípio. São extraídas  $n$  observações  $X_1, X_2, \dots, X_n$  de  $X$ , independentes. Construa um intervalo de confiança de 95% para  $p$  a partir da estatística  $f = \bar{X}$  (frequência amostral).

Sendo  $\bar{X} = \sum_k X_k/n$  e  $\sum_k X_k \sim Binom(n, p)$ , então temos que  $n\bar{X} = \sum_k X_k \sim Binom(n, np)$

Para que o intervalo tenha 95% de confiança,  $1 - \alpha = 0.95 \implies \alpha = 0.05$  e  $\alpha/2 = 0.025$ . Sendo  $E$  extremo do intervalo de confiança, sabemos que

$$E = (z_{\alpha/2}) \frac{s}{\sqrt{n}}$$

Com  $z_{\alpha/2}$  percentil da distribuição relativa a  $\alpha/2$ .

Como é válido que, para a distribuição binomial,  $Var[X] = \sigma^2 = p(1-p)$ , então  $s = \sqrt{p(1-p)}$ . O limite  $E$  é dado por

$$E = \sum_{i=0}^{np} \binom{n}{i} p^i (1-p)^{n-i} \frac{\sqrt{p(1-p)}}{\sqrt{n}}$$

Em abordagem "conservadora", ou seja, considerando um intervalo maior aproximado por uma distribuição normal ( $n$  grande), podemos assumir válido que

$$E = z_{\alpha/2} \frac{1}{2\sqrt{n}}$$

Dessa forma

$$E = \int_{-\infty}^{0.0025} N(0, 1) \frac{1}{2\sqrt{n}} dx$$

representa os extremos (esquerda, para  $\alpha/2$ , e direita para  $1 - \alpha/2$ ) do intervalo de confiança.